

文章编号:1671-1637(2022)03-0251-12

低可见度环境下基于同步定位与构图的 无人驾驶汽车定位算法

高 扬¹, 曹王欣¹, 夏洪垚¹, 赵亦辉²

(1. 长安大学 汽车学院, 陕西 西安 710064; 2. 西安煤矿机械有限公司, 陕西 西安 710200)

摘 要:为在大范围低可见度环境下实现无人驾驶汽车的高精度定位,基于 VINS-Mono 算法的系统框架,在系统的前端与后端分别增添了 RFAST 弱光图像增强模块与 VG 融合定位模块,提出了一种融合定位算法 LVG_SLAM;RFAST 弱光图像增强模块采用小波变换将原始输入图像的细节信息与亮度信息分离,对于包含原始图像噪声的细节信息通过统一阈值和均值滤波 2 种方式实现噪声抑制,并利用双边纹理滤波算法进行细节增强,在此基础上,根据多尺度 Retinex 算法增强图像的对比度,提高低可见度环境下角点提取的成功率,从而保证图像跟踪的稳定性,改善定位算法的鲁棒性;基于无迹卡尔曼滤波算法,VG 融合定位模块将 GNSS 定位信息与惯性导航测量信息进行松耦合,融合定位结果作为约束引入 VI-SLAM 后端,通过联合非线性优化的方式减少累积误差对算法定位精度的影响。计算结果表明:相较于 VINS-Mono 算法,改进的 LVG_SLAM 融合定位算法在 EuRoC 与 Kitti 公开数据集上表现更加出色,均方根误差分别降低了 38.76%与 58.39%,运动轨迹更贴近真实轨迹;在实际夜晚道路场景下, LVG_SLAM 算法将定位误差控制在一定范围内,顺利检测到闭环使得定位表现得到大幅改善,均方根误差、平均误差、最大误差、中位数误差分别降低了 79.61%、82.50%、71.31%、83.77%,与 VINS-Mono 算法相比,在定位精度与鲁棒性方面具有明显的优势。

关键词:智能交通;环境感知;同步定位与构图;弱光图像增强;噪声抑制;融合定位

中图分类号:U491.2 **文献标志码:**A **DOI:**10.19818/j.cnki.1671-1637.2022.03.020

Driverless vehicle positioning algorithm based on simultaneous positioning and mapping in low-visibility environment

GAO Yang¹, CAO Wang-xin¹, XIA Hong-yao¹, ZHAO Yi-hui²

(1. School of Automobile, Chang'an University, Xi'an 710064, Shaanxi, China;

2. Xi'an Coal Mining Machinery Co., Ltd., Xi'an 710200, Shaanxi, China)

Abstract: In order to achieve high-precision positioning for driverless vehicles in a large-scale and low-light environment, a fused positioning algorithm LVG_SLAM was proposed based on the system framework of the VINS-Mono algorithm. In LVG_SLAM, a RFAST low-light image enhancement module and a VG fusion positioning module were proposed and then added. The RFAST low-light image enhancement module applied a wavelet transform to separate the detailed

收稿日期:2021-12-11

基金项目:国家重点研发计划(2019YFB1600100);陕西省自然科学基金项目(2019JLP-07)

作者简介:高 扬(1982-),男,江西吉安人,长安大学副教授,工学博士,从事移动机器人导航技术与人工智能技术研究。

引用格式:高 扬,曹王欣,夏洪垚,等.低可见度环境下基于同步定位与构图的无人驾驶汽车定位算法[J].交通运输工程学报,2022,22(3):251-262.

Citation:GAO Yang, CAO Wang-xin, XIA Hong-yao, et al. Driverless vehicle positioning algorithm based on simultaneous positioning and mapping in low-visibility environment[J]. Journal of Traffic and Transportation Engineering, 2022, 22(3): 251-262.

information from the brightness information. In the RFAST module, the unified threshold and mean filter were applied to filter the detailed noisy information from the original image while the bilateral texture filter algorithm was applied to enhance the detail information. After that, the multi-scale retinex algorithm was proposed to further enhance the contrast of the image to improve the success rate of corner extraction in a low-light environment, benefit from which, both the stability of image tracking and the robustness of the positioning algorithm were improved. Using an unscented Kalman filter (UKF) algorithm, the VG fusion positioning module loosely fused the positioning information from both the global navigation satellite system (GNSS) and the inertial navigation equipment. The fused positioning result was introduced as a constraint into the back end of the LVG_SLAM algorithm, benefit from which, the influence of cumulative error on the positioning accuracy of the algorithm was reduced by a joint nonlinear optimization. Analysis results show that compared with the VINS-Mono algorithm, the LVG_SLAM algorithm performs better on the EuRoC and Kitti public datasets, and the root mean square error reduces by 38.76% and 58.39%, respectively, so that the motion trajectory estimated by the LVG_SLAM algorithm is closer to the real trajectory. In an experiment of night road scene, the LVG_SLAM algorithm successfully constrains the positioning error into a certain range, and detects the closed loop, which greatly improves the positioning performance. The root mean square error, average error, maximum error, and median error reduce by 79.61%, 82.50%, 71.31%, and 83.77%, respectively. Compared with the VINS-Mono algorithm, the proposed LVG_SLAM algorithm has obvious advantages in both positioning accuracy and robustness. 4 tabs, 12 figs, 26 refs.

Key words: intelligent transportation; environmental perception; simultaneous localization and mapping; low-light image enhancement; noise suppression; fusion positioning

Author resume: GAO Yang(1982-), male, associate professor, PhD, nchygy@chd.edu.cn.

Foundation items: National Key Research and Development Program of China (2019YFB1600100); Natural Science Foundation of Shaanxi Province (2019JLP-07)

0 引 言

同步定位与构图 (Simultaneous Localization and Mapping, SLAM) 技术主要通过地图匹配来提供高精定位结果,在移动机器人、无人驾驶、虚拟现实等领域具有广泛的应用前景^[1]。基于视觉传感器与惯性测量单元(Inertial Measurement Unit, IMU)融合的视觉惯性 SLAM (Visual-Inertial Simultaneous Localization and Mapping, VI-SLAM) 技术,一方面利用相机获取丰富的环境特征信息,另一方面通过 IMU 计算自身相对运动并提供真实的尺度信息,多源信息的融合使 VI-SLAM 可以在光照强度足够的环境下实现高精定位^[2]。然而,面对类似夜晚道路场景的大范围低可见度环境,VI-SLAM 存在环境特征信息采集困难以及累积误差难以消除的问题,导致系统定位精度下降甚至无法完成定位。

目前,国内外学者对低可见度环境下的图像特征提取方法已经开展一系列研究工作。Huang 等^[3]提

出一种基于多特征提取算法的 SLAM 系统,通过采用多种特征提取算法提高检测出的特征点数量,从而获取更多图像特征信息,在低可见度环境下依然能保持系统的鲁棒性,但其在曝光强度相差巨大的环境下难以正常运行;Wang 等^[4]基于 RGB-D 相机的 SLAM 模型提出一种改进的 Gamma 自适应矫正算法,可以根据图像的灰度平均值与经验值对 Gamma 矫正参数进行自适应调整,改善图像匹配的准确性与鲁棒性,从而提高 SLAM 系统在低可见度环境下的定位精度,但其对采集的弱光图像并未进行降噪处理,未能解决弱光图像质量差、包含较多噪声的问题;Lore 等^[5]提出了 LLNET 与 S-LLNET 两种网络结构,通过合成的低光照数据集对网络进行训练,利用堆叠稀疏去噪自编码器实现了弱光图像的亮度增强以及噪声抑制,但训练使用的人工添加的图像噪声与真实场景下的低光照图像相比仍有些差异;Wei 等^[6]提出一种基于 Retinex 理论的卷积神经网络模型 RetinexNet,主要包括分解模型、

调整模型和重建三部分,同时公开了第一个用于弱光环境下图像增强的 LOL 数据集,但这种通过无监督学习得到的光照图比较模糊,影响了图像增强的整体效果;Dabov 等^[7]将图像的自然场景统计特性(Natural Scene Statistics, NSS)与稀疏性相结合提出了一种三维块匹配滤波算法(Block-Matching and 3D Filtering, BM3D),通过对具有相似结构的二维图块进行协同滤波处理,以加强相似图块的稀疏性并抑制图块中的噪声,但在实际应用中需要搭配合适的噪声水平估计算法才能达到最佳的降噪效果;Zhang 等^[8]提出了一种降噪卷积神经网络(Denoising Convolutional Neural Network, DnCNN),在 GPU 的支持下能够充分且高效地挖掘图像特征信息,高质量地实现图像与噪声信号的分离,但需要根据图像受噪声干扰的严重程度训练相适应的特定降噪模型,在环境适应性上仍有待改进。

虽然,上述算法在一定程度上可以改善 VI-SLAM 在室外大范围低可见度复杂环境下的表现,但大多忽略了环境光照强度变化带来的影响,实时性与定位精度仍有待提高,同时累积误差的问题也没有得到解决,因此,本文基于 VINS-Mono^[9] 框架,提出一种可适用于室外大范围低可见度复杂环境的 LVG_SLAM 算法。一方面对 VINS 的前端数据预处理模块加以改进,添加了弱光图像增强模块,对输入的每一帧图像进行噪声抑制与细节增强,以提高定位系统的鲁棒性。另一方面将全球导航卫星系统(Global Navigation Satellite System, GNSS)的定位信息引入 VI-SLAM 系统^[10],利用 GNSS 绝对定位特性消除系统的累积误差,从而进一步提高定位精度。

1 基于 VINS-Mono 改进的 LVG_SLAM 算法

针对大范围低可见度环境下 VI-SLAM 角点提取困难、累积误差难以消除的问题,本文基于 VINS-Mono 算法提出一种改进的 LVG_SLAM 定位算法,在前端加入弱光图像增强模块并将原有的 Shi-Tomasi 角点替换为鲁棒性更强的 FAST 角点^[11],以增加图像提取的角点数量,增强系统的鲁棒性。同时引入 GNSS 定位信息,实现 VI-SLAM 与 GNSS 的融合定位,进一步消除累积误差对定位精度的影响。

LVG_SLAM 算法主要包括数据预处理、系统初始化、后端优化与 GNSS 融合定位四大模块,算

法框架如图 1 所示。数据预处理首先将采集到的弱光图像进行噪声抑制与增强处理,然后采用 FAST 算子提取图像特征,并通过 LK 光流法^[12]进行追踪。系统初始化主要根据图像特征与对应的 IMU 数据,提供相机与路标的初始位姿,并对真实尺度、重力方向与加速度计偏置进行估计。后端优化模块负责对提供的相机位姿、图像特征与 IMU 信息进行捆绑调整(Bundle Adjustment, BA)优化^[13],得到 VI-SLAM 的位姿估计结果。GNSS 融合定位首先将坐标变换后的 GNSS 定位信息与 IMU 数据通过无迹卡尔曼滤波算法进行融合,随后联合 VI-SLAM 的定位结果进行非线性优化,得到 LVG_SLAM 的最终定位结果。

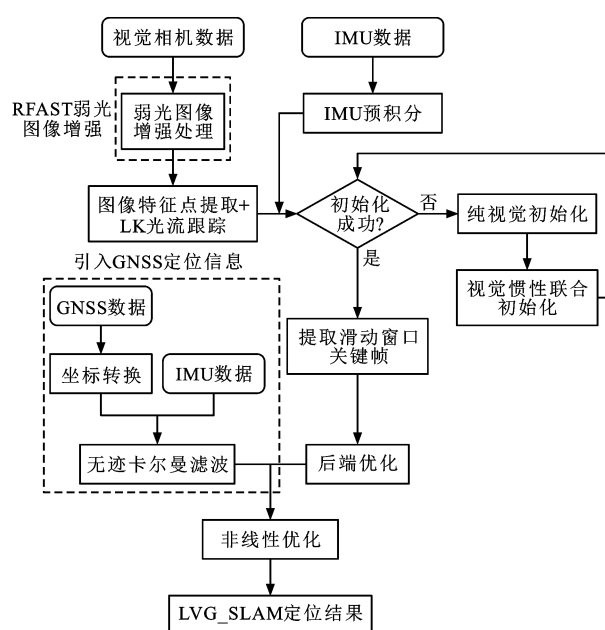


图1 LVG_SLAM 算法框架

Fig. 1 Framework of LVG_SLAM algorithm

1.1 RFAST 弱光图像增强算法

图像在采集、传输记录过程中往往会受到多种因素的干扰,导致图像质量不同程度地下降,这类不必要或多余的干扰信息形成图像噪声。一般认为图像噪声服从高斯分布,直接影响后续 VI-SLAM 的定位效果^[14]。在低可见度环境下 VI-SLAM 易因采集的图像对比度低、动态范围小并且包含较多噪声等原因,难以提取到足够数量的角点,从而导致轨迹漂移甚至定位失败,因此,本文提出一种 RFAST 弱光图像增强算法,以改善低可见度环境下 VI-SLAM 系统的定位精度与鲁棒性,算法流程如图 2 所示。

RFAST 算法首先通过小波变换将原始输入图像 S 分解为低频分量 S_l 与高频分量 S_h ,使图像的亮度信息与细节信息分离。对低频分量 S_l 的亮度值




图 2 RFAST 弱光图像增强算法

Fig. 2 RFAST enhancement algorithm for low-light images

进行伽马校正与平滑处理,根据 Retinex 理论得到照明图像 L ,同时采用统一阈值和均值滤波的方法对高频分量 S_h 进行噪声抑制,处理后与低频分量 S_l 通过小波逆变换实现图像重组,以滤去原始输入图像中包含的噪声。随后基于双边纹理滤波的方法^[15]对降噪图像 \hat{S} 进行细节增强,在提高图像的对比度的同时保持边缘清晰,避免图像的失真与细节缺失。最后对经过降噪、细节增强后的图像 S' 与照明图像 L 使用多尺度 Retinex (Multi-Scale Retinex, MSR) 算法^[16]得到增强图像 R 。

1.1.1 基于小波变换的图像分解

为了将图像的亮度信息与细节信息分离,本文将图像视为离散的二维信号,基于小波变换理论与 Mallat 图像分解算法^[17]将原始输入图像 S 分解为低频分量 S_l 与高频分量 S_h ,高频分量进一步分为水平、垂直、对角 3 个方向的高频分量 S_h^H 、 S_h^V 、 S_h^D ,如图 3 所示, n 为图像分解级数。各分量的具体计算如下

$$\begin{cases} S_l(j) = [F_l^H \otimes S_l(j-1)] \otimes F_l^V \\ S_h^H(j) = [F_h^H \otimes S_l(j-1)] \otimes F_h^V \\ S_h^V(j) = [F_h^V \otimes S_l(j-1)] \otimes F_h^H \\ S_h^D(j) = [F_h^H \otimes S_l(j-1)] \otimes F_h^V \end{cases} \quad (1)$$




图 3 图像小波分解

Fig. 3 Wavelet decomposition of image

式中: j 为图像尺度; \otimes 为图像卷积运算; F_l^H 、 F_l^V 分别为水平、垂直方向的低通滤波器; F_h^H 、 F_h^V 分别为水平、垂直方向的高通滤波器。

图像经过小波分解后,其灰度信息主要存在于低频分量 S_l ,细节信息与原始噪声则主要存在于高频分量 S_h ^[18]。对高频分量进行降噪与细节增强处理,可以提高角点提取的准确率,而包含大多数灰度信息的低频分量可用于估计照明图像,以增加角点提取的数量。

1.1.2 照明图像估计

Retinex 理论^[19]认为传感器感知到的颜色由物体表面的反射图像 R 决定,其基本思想是使用原始图像 S 估计照明图像 L ,从而分解出反射图像 R ,但并没有考虑噪声的影响,因此,本文对原始图像 S 的估计增加一个噪声项 e ,新的原始图像估计公式为

$$S = S_l + S_h = LR_l + LR_h + e \quad (2)$$

式中: R_l 、 R_h 分别为反射图像 R 的低频、高频分量; e 为均值为 0 的高斯噪声。

低频分量 S_l 包含了原始图像 S 中缓慢变化的信息,考虑到照明图像 L 具有缓变平滑性^[20],因此, S_l 决定了照明图像。为防止增强后的图像对比度过高,提高算法在复杂光照变化下的鲁棒性,本文对低频分量 S_l 的亮度 S_l^c 进行 Gamma 校正,即

$$L_G = \left(\frac{S_l^c}{2^b - 1} \right)^\gamma (2^b - 1) \quad (3)$$

式中: b 为图像色深; γ 为 Gamma 校正参数; L_G 为 Gamma 校正后的图像。

针对 L_G 中存在少量细节特征无法满足照明图像平滑特性的问题,本文采用一种图像结构感知平滑求解器^[21]在保留图像结构的同时对 L_G 进行平滑处理,以得到最终的照明估计图像 \hat{L} ,即

$$\begin{cases} \hat{L} = \frac{L_G}{I + \sum_{d \in \{H, V\}} D_d^T O(\tilde{W}_d) D_d} \\ \tilde{W}_d = \sum_{r \in \Omega_i} \frac{W_d(r)}{|\nabla_d L_G(r)| + \epsilon} \end{cases} \quad (4)$$

式中: \hat{L} 为平滑处理后的照明图像; I 为单位矩阵;

Ω_t 为以像素 t 为中心的局部图像区域; r 为 Ω_t 范围内的任一像素; $W_d(r)$ 为像素 r 对应的权重矩阵, 可分为水平方向 $W_H(r)$ 与垂直方向 $W_V(r)$; D_d 为向前差分运算符; ∇_d 为一阶差分算子; $O(\tilde{W}_d)$ 为使用 \tilde{W}_d 构建的对角矩阵; ϵ 为一个防止分母为 0 的极小正数。

1.1.3 噪声抑制与细节增强

为减轻图像噪声对细节增强的影响, 提高 FAST 角点提取的准确率, 根据噪声幅值的差异, 本文采用统一阈值去噪和均值滤波^[22] 2 种方式对图像高频分量 S_h 进行噪声抑制。对于幅值较小的绝大部分噪声, 统一阈值去噪^[23] 可以在抑制噪声的同时保留信号的原始信息, 具体为

$$\begin{cases} \hat{w} = \begin{cases} w & (|w| \geq T) \\ 0 & (|w| < T) \end{cases} \\ T = \sigma \sqrt{a \ln(N)} \end{cases} \quad (5)$$

式中: w 为处理前噪声对应的小波变换系数; \hat{w} 为

$$\frac{(1,1,1,1,1)}{5}$$

(a) 水平方向滤波模板

$$\frac{(1,1,1,1,1)^T}{5}$$

(b) 竖直方向滤波模板

$$\frac{1}{9} \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}$$

(c) 对角方向滤波模板

图 4 均值滤波模板

Fig. 4 Templates of mean filter

考虑到 FAST 算子主要依靠图像的纹理细节与边缘信息提取角点, 为进一步增加弱光图像角点提取的数目, 改善系统追踪的鲁棒性, 本文采用基于双边纹理滤波的方法^[15] 对降噪后的图像进行细节增强, 以在提高图像的对比度的同时保持边缘清晰。

首先将图像分解为多个图像块, 然后通过相关全变差 κ 来衡量图像块中的显著结构信息, 并以此构建参考图像 G , 最后对原始图像 S 与参考图像 G 进行双边滤波得到细节增强后的图像, 即

$$\begin{cases} \kappa(\Omega_t) = \Delta(\Omega_t) \frac{\max_{r \in \Omega_t} |(\partial S)_r|}{\sum_{r \in \Omega_t} |(\partial S)_r| + \epsilon} \\ G_t = \alpha_t B_q + (1 - \alpha_t) B_t \\ \alpha_t = 2 \left\{ \frac{1}{1 + \exp[-\lambda(\kappa(\Omega_t) - \kappa(\Omega_q))]} - 0.5 \right\} \end{cases} \quad (7)$$

式中: $\Delta(\Omega_t)$ 为 Ω_t 中像素灰度的最大差值; $(\partial S)_r$ 为 $r \in \Omega_t$ 的梯度能量; q 为 Ω_t 中具有最小 κ 值的像素; λ 为控制权重 α_t 从边缘到平滑/纹理过渡的变化程度因子。

1.2 VG 融合定位算法

VI-SLAM 主要采用地图匹配技术实现定位,

处理后的小波变换系数; T 为阈值^[23]; σ 为噪声的标准差; N 为小波分解后得到的小波变换系数的个数; a 为尺度因子。

对于信号畸变导致的幅值较大的噪声, 其在图像灰度中表现为一个突变值, 导致 FAST 算子容易错误地将该噪声提取为角点, 而均值滤波具有良好的平滑性, 能够较好地抑制高频分量 S_h 中幅值较大的噪声, 因此, 本文在对高频分量 S_h 进行阈值处理后, 进一步采用均值滤波的方法对其进行噪声抑制。

由式(1)可知, 高频分量 S_h 分解为水平、垂直、对角 3 个分量。为了达到更好的滤波效果, 本文分别对其采用如图 4 所示的均值滤波模板进行滤波处理, 处理后图像在像素 t 处的灰度值 B_t 可以表示为

$$B_t = \frac{1}{M} \sum_{r \in \Omega_t} f(r) \quad (6)$$

式中: $f(r)$ 为像素 r 对应灰度值; M 为 Ω_t 中所包含像素点的数目。

其不依赖先验地图信息, 仅通过视觉传感器与 IMU 即可在自行绘制环境地图的基础上实现高精定位, 但在没有发生回环检测时存在累积误差。GNSS 定位作为绝对定位技术的代表, 通过接收到的卫星信号能够解析出搭载设备的全局坐标, 这种定位方式不存在累积误差, 但在信号受限的城市道路或室内等特殊环境下, 定位精度受到影响, 甚至无法完成定位, 因此, 本文提出了一种 GNSS 与 VI-SLAM 融合定位的 VG 算法。

在有 GNSS 信号时, VG 算法通过融合 GNSS 定位信息可以纠正 VI-SLAM 长时间大范围运行所造成的累积误差, 从而控制定位算法的误差累积程度, 有效提高定位精度与鲁棒性; 在没有 GNSS 信号时, 算法内部的 VI-SLAM 依然可以鲁棒运行, 通过回环检测等模块消除累积误差, 提供高精度的定位结果。

VG 算法的融合步骤如图 5 所示, 为减少 GNSS 定位结果的方差, 先将 GNSS 与 IMU 的定位结果通过无迹卡尔曼滤波 (Unscented Kalman Filter, UKF) 进行融合, 随后将融合定位结果 P^g 作为一个

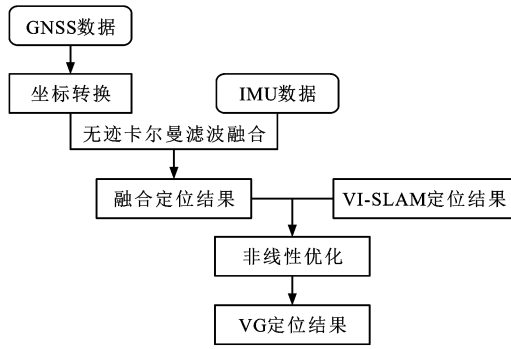


图5 VG融合定位算法

Fig. 5 VG fusion positioning algorithm

约束与 VI-SLAM 的定位结果 P^s 进行非线性优化, 从而减少累积误差对定位精度的影响, 提高系统在大范围复杂环境下的鲁棒性。

1.2.1 基于无迹卡尔曼滤波的 GNSS 与 IMU 融合定位

IMU 通过对测量值进行积分能够在短时间内准确估计车辆位姿, 然而存在累积误差, 引入无迹卡尔曼滤波算法融合 GNSS 与 IMU 定位信息可有效提高定位精度^[24], 为此建立系统的观测方程与状态方程。由于车辆正常行驶较少涉及滚转与俯仰角变化, 因此, 将汽车位姿 P 简化为世界坐标系 x, y, z 轴下的坐标 p^x, p^y, p^z 与偏航角 θ , 即 $P = (p^x, p^y, p^z, \theta)$ 。

系统的观测方程为

$$Z_k = \begin{bmatrix} p_k^x \\ p_k^y \\ p_k^z \\ \theta_k \end{bmatrix} + U_k \quad (8)$$

式中: Z_k 为 k 时刻转换到世界坐标系后的 GNSS 定位结果, 也是系统观测值; $p_k^x, p_k^y, p_k^z, \theta_k$ 为车辆 k 时刻的位姿; U_k 为 k 时刻的观测噪声, 一般认为其服从零均值的高斯分布。

系统的状态方程为

$$X_{k+1} = \begin{bmatrix} p_{k+1}^x \\ p_{k+1}^y \\ p_{k+1}^z \\ \theta_{k+1} \\ v_{k+1}^x \\ v_{k+1}^y \\ v_{k+1}^z \end{bmatrix} = \begin{bmatrix} p_k^x + v_k^x \Delta t + a_k^x \Delta t^2 \\ p_k^y + v_k^y \Delta t + a_k^y \Delta t^2 \\ p_k^z + v_k^z \Delta t + a_k^z \Delta t^2 \\ \theta_k + \frac{v_k^x \tan(\varphi_k)}{R \sin(\theta_k)} \Delta t \\ v_k^x + a_k^x \Delta t \\ v_k^y + a_k^y \Delta t \\ v_k^z + a_k^z \Delta t \end{bmatrix} + Q_k \quad (9)$$

式中: Δt 为相邻时刻的时间间隔; X_{k+1} 为 $k+1$ 时刻的系统状态向量; $v_{k+1}^x, v_{k+1}^y, v_{k+1}^z$ 分别为 $k+1$ 时刻

车辆沿 x, y, z 轴的速度分量; a_k^x, a_k^y, a_k^z 分别为 k 时刻车辆沿 x, y, z 轴的加速度, 均由 IMU 给出; φ_k 为 k 时刻车辆转向角; Q_k 为 k 时刻的系统噪声, 一般认为其服从零均值的高斯分布。

依据上述系统模型, 依据 UKF 对 GNSS 与 IMU 的定位结果进行融合, 获得融合定位结果 P^s 。具体应用过程此处不再赘述。

1.2.2 GNSS、IMU 与 VI-SLAM 融合定位

由于 GNSS 的数据刷新频率与 VI-SLAM 的数据刷新频率往往不一致, 为了确保数据的对齐, 规定当二者的观测时间差小于 50 ms 时对齐为同一时刻的观测值。为融合 GNSS、IMU 与 VI-SLAM 的定位结果, 建立优化系统, 其中待优化变量 χ 为

$$\chi = (P_0^s, P_1^s, \dots, P_k^s) \quad (10)$$

式中: P_k^s 为融合定位算法 VG 在 k 时刻对无人驾驶汽车的位姿估计。

考虑到 VI-SLAM 能够在相邻两次定位观测值之间获得准确的运动估计, 因此 VI-SLAM 负责提供相邻观测时刻位姿的变化量, 以 P^s 作为定位初始结果, 依据 P^s 的输出节拍为离散时间步长建立误差函数 $R(\chi)$ 如下

$$R(\chi) = \sum_{k=0}^{N^s} R^s(k, k+1) + R^g(k) \quad (11)$$

$$\begin{cases} R^s(k, k+1) = \|P_{k+1}^s - P_k^s\|^2 - \|P_{k+1}^v - P_k^v\|^2 \\ R^g(k) = \|P_k^g - P_k^v\|^2 \end{cases}$$

式中: $R^s(k, k+1)$ 为 VI-SLAM 与 VG 在 k 时刻至 $k+1$ 时刻间估计所得的车辆位姿变化的偏差; $R^g(k)$ 为 k 时刻利用 VG 算法与仅用 GNSS、IMU 融合定位结果间的偏差, 若 GNSS 在 k 时刻没有信号输出, 规定 $R^g(k)$ 的值为 0; N^s 为相邻两时刻内 VI-SLAM 输出的运动估计值数量; P_k^s 为利用 VI-SLAM 在 k 时刻的车辆位姿估计结果; P_k^g 为 k 时刻利用 GNSS 与 IMU 的融合定位结果。

将误差函数 $R(\chi)$ 转换为最小二乘问题并求解, 即可得到 VG 融合定位算法对无人驾驶汽车的位姿估计。

2 试验验证

为验证本文提出的 LVG_SLAM 算法的有效性, 首先在 EuRoC 数据集^[25]上测试 RFAST 算法在低可见度环境下的图像增强效果, 然后采用 Kitti 数据集^[26]验证 VG 融合定位算法的可靠性, 最后在

夜晚道路场景下进行真实环境的实车试验,验证 LVG_SLAM 算法在室外低可见度环境下的鲁棒性。本文的试验环境为 Ubuntu 18.04,硬件设备为联想小新 air15(CPU 为 i5-10210U,主频为 2.11 GHz,运行内存为 12 GB),采用小觅双目相机 D1000-IR-120 与星网宇达卫星信号接收机。

2.1 弱光图像增强试验

在 VINS-Mono 前端加入 RFAST 弱光图像增强模块,称其为 VINS_LOV 算法。验证 RFAST 算法在弱光环境下对角点提取数量以及 VI-SLAM 系统的增益效果,本文选取 EuRoC 数据集中的 MH04_difficult 子集作为评测数据,对比测试了原始 VINS-Mono 与 VINS_LOV 算法的表现,试验结果如图 6 所示。

由图 6 与表 1 可知:当环境的光照强度足够时,图像增强前后提取到的角点数量并未发生显著变化;当光照强度不足时,图像增强后提取的角点数量相比于原始图像大幅增加,可见本文提出的 RFAST 弱光图像增强算法在低可见度环境下能够大幅改善图像的细节特征,有效增加角点提取的数目,同时在正常光照环境下也能维持稳定的工作性能。

表 1 角点提取数量对比

Table 1 Comparison of corner extraction numbers

图像	角点提取个数		提升幅度/%
	原始图像	增强图像	
1	264	277	4.924
2	173	219	26.590
3	130	235	80.769




图 6 RFAST 弱光图像增强算法试验结果

Fig. 6 Experimental results of RFAST low-light image enhancement algorithm

图 7(a)、(b)分别展示了 VINS-Mono 与 VINS_LOV 在 xOy 平面与 xOz 平面上的运动轨迹对比,可以看出:VINS_LOV 的运动轨迹更加贴合于真实轨迹,而 VINS-Mono 运动轨迹的起点与终点发生了较为明显的偏移。采用 MH04_difficult 数据集进行 5 次试验,计算其运动轨迹误差各项评价指标的

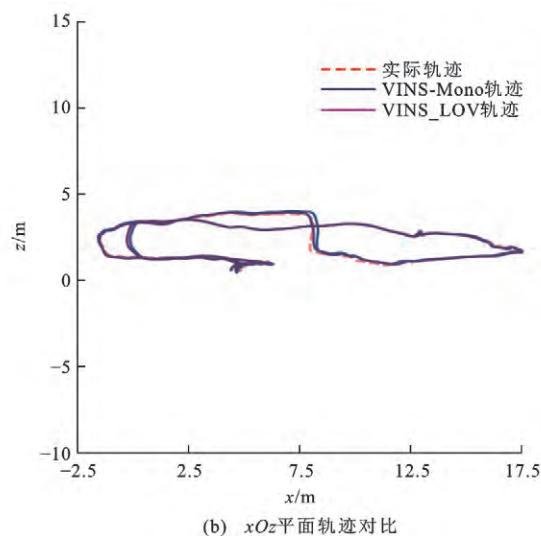



图 7 VINS-Mono 与 VINS_LOV 运动轨迹对比

Fig. 7 Comparison of motion trajectories between VINS-Mono and VINS_LOV

表 2 VINS-Mono 与 VINS_LOV 误差对比

Table 2 Comparison of errors between VINS-Mono and VINS_LOV

评价指标	VINS_LOV	VINS-Mono
均方根误差/m	0.199 629	0.325 981
平均误差/m	0.168 457	0.307 540
最大误差/m	0.455 183	0.472 395
最小误差/m	0.014 413	0.050 871
中位数误差/m	0.130 769	0.365 190

2.2 GNSS 与 VI-SLAM 融合定位试验

为测试 VG 融合定位算法在室外大范围环境下的表现,本文采用 Kitti 数据集的 09 子集对 VINS-Mono 与 VG 进行对比试验。由于 Kitti 数据集仅提供高精度 GNSS 定位结果,故本文在该结果的基础上添加均值为 4 m、标准差为 1 m 的高斯噪声以模拟 GNSS 定位信息的输入。

图 8(a)、(b)分别给出了 VINS-Mono、VG 算法所得运动轨迹和真实轨迹的对比结果,二者运动轨迹误差的各项指标如表 3 所示。由图 8 与表 3 不难看出:VINS-Mono 在起始阶段的运动轨迹与真实轨迹基本一致,但随着误差的不断累积,其轨迹终点发生明显偏移。事实上,SLAM 算法主要依靠回环检测消除或削减累积误差,在本例中由于光照强度不足导致 VINS-Mono 未能成功回环,累积误差也未

平均值,结果如表 2 所示,VINS_LOV 的误差评价指标均优于 VINS-Mono,均方根误差平均降低了 38.76%,由此可见本文提出的 RFAST 弱光图像增强算法能够有效增加图像角点提取的数目,从而提高 VI-SLAM 系统在低可见度环境下的定位精度与鲁棒性。

能消除。而采用本文算法后,一方面 VG 在 VINS-Mono 的基础上融入了不存在累积误差的 GNSS 定位信息,其整体运动轨迹与真实轨迹基本保持一致,另一方面回环检测得以成功运行,因此,大部分评价指标得到明显优化,均方根误差平均降低了 58.39%。

可见,本文提出的 VG 融合定位算法能够结合 VI-SLAM 短时间内定位精度较高与 GNSS 不存在累积误差的优点,改善 VI-SLAM 在室外大范围环境下表现较差的问题。

表 3 VINS-Mono 与 VG 误差对比

Table 3 Comparison of errors between VINS-Mono and VG

评价指标	VG	VINS-Mono
均方根误差/m	6.238 162	14.991 978
平均误差/m	5.578 558	13.337 583
最大误差/m	11.140 413	33.867 193
最小误差/m	0.126 134	5.506 336
中位数误差/m	5.704 954	10.387 250

2.3 夜晚道路环境下 LVG_SLAM 算法实车试验

为验证 LVG_SLAM 算法的有效性,本文在夜晚道路环境下进行实车试验,试验平台为搭载小觅相机与卫星接收设备的奇瑞小蚂蚁 eQ1 纯电动汽车,其中 GNSS 定位数据为高精度 RTK 差分数据,相机采样频率为 10 Hz,IMU 采样频率为 200 Hz,卫星信号接

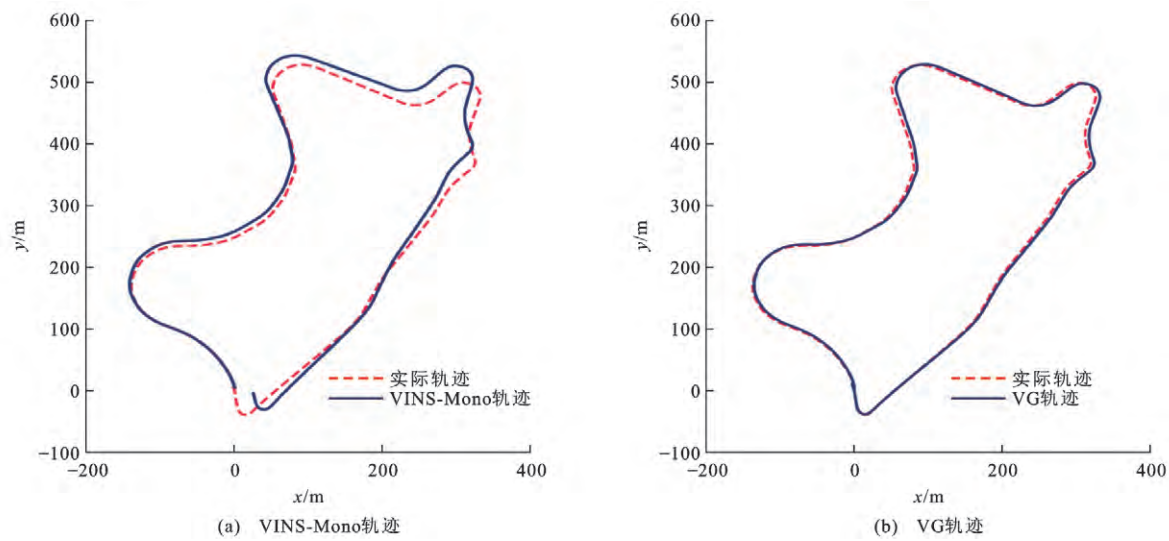


图 8 VINS-Mono 与 VG 运动轨迹对比

Fig. 8 Comparison of motion trajectories between VINS-Mono and VG

收设备输出的 GNSS 与 IMU 融合数据的频率为 10 Hz,总体设备如图 9 所示。为了获得车辆运动的真实轨迹,试验中始终控制车辆按规划路线行驶,图 10 展示了试验环境的卫星地图与实际场景。



图 9 实车试验平台

Fig. 9 Test platform for actual vehicles

图 11 为夜晚道路场景下 VINS-Mono 与 LVG_SLAM 算法的图像增强效果对比结果,图 12(a)、(b)则分别给出了 2 种算法与真实轨迹的对比结果:不难看出 VINS-Mono 的运动轨迹出现了较为严重的漂移,起点与终点位置偏移较大,而 LVG_SLAM 的运动轨迹在绕行一周后顺利闭合,与真实轨迹基本一致。同时由表 4 可以发现:除最小误差外 LVG_SLAM 各项评价指标均优于 VINS-Mono,均方根误差平均降低了 79. 61%,可见本文提出的 LVG_SLAM 算法能够显著提高 VI-SLAM 在室外低可见度环境下的定位精度与鲁棒性。



(a) 试验场地卫星地图



(b) 车辆行驶的实际场景

图 10 夜晚道路试验场景

Fig. 10 Experimental scenes of night road

表 4 夜晚道路试验运动轨迹误差对比

Table 4 Comparison of motion trajectory errors in night road experiment

评价指标	LVG_SLAM	VINS-Mono
均方根误差/m	2. 692 074	13. 204 907
平均误差/m	1. 951 224	11. 147 574
最大误差/m	7. 870 044	27. 429 693
最小误差/m	0. 114 326	0. 092 444
中位数误差/m	1. 489 543	9. 178 928




图 11 图像增强效果对比

Fig. 11 Comparison of image enhancement effects




图 12 夜晚道路试验轨迹对比

Fig. 12 Comparison of trajectories in night road experiment

为了验证 RFAST 弱光图像增强算法的实时性能,本文对不同分辨率的输入图像展开了测试。当图像分辨率为 $640 \text{ 像素} \times 480 \text{ 像素}$ 时,平均每张图像耗时 24.5652 ms ,通过保存原始照片的时间戳数据可知:RFAST 模块可以在不影响定位算法实时性的前提下满足相机 40 Hz 的采样频率;当图像分辨率为 $1280 \text{ 像素} \times 720 \text{ 像素}$ 时,RFAST 弱光图像增强模块耗时显著增加,平均耗时为 74.8864 ms ,此时 RFAST 模块可以在不影响定位算法实时性的前提下满足相机 12.5 Hz 的采样频率。为了保证定位算法的准确性,VINS-Mono 与本文改进的 LVG-SLAM 算法均要求图像的输入频率不得小于 10 Hz 。由测试结果可知,本文提出的 RFAST 弱光图像增强算法在对图像进行处理的同时能够兼顾定位算法的实时性需求。

3 结 语

(1)针对低可见度环境下,VI-SLAM 角点提取困难与噪声集中的问题,提出一种弱光图像增强算法 RFAST,对输入图像进行小波变换、噪声抑制与细节增强,有效增加图像提取的角点数量,从而保证图像跟踪的稳定性。

(2)为了控制定位算法的误差累积程度,提出一种 VG 融合定位算法,将 GNSS 定位信息引入到 VI-SLAM 当中,从而纠正 VI-SLAM 长时间大范围运行所造成的累积误差,提高定位算法的精度。

(3)在 VINS-Mono 的前端、后端分别引入了 RFAST 弱光图像增强与 VG 融合定位模块,称之为 LVG-SLAM 算法并在公开数据集和实际场景下进行试验。试验结果表明:与传统 VI-SLAM 算法相比,在室外大规模低可见度环境下 LVG-SLAM 算法可以提高无人驾驶汽车的定位精度与鲁棒性。

(4)下一步将尝试在不同的 VI-SLAM 框架中添加 RFAST 弱光图像增强与 VG 融合定位模块,并在各类数据集上展开测试,探究算法在不同光照条件下的性能与稳定性。

参考文献:

References:

- [1] BRESSON G, ALSAYED Z, YU Li, et al. Simultaneous localization and mapping: a survey of current trends in autonomous driving[J]. IEEE Transactions on Intelligent Vehicles, 2017, 2(3): 194-220.
- [2] DOMÍNGUEZ-CONTI J, YIN Jian-feng, ALAMI Y, et al. Visual-inertial SLAM initialization: a general linear formulation

- and a gravity-observing non-linear optimization[C]//IEEE. 2018 IEEE International Symposium on Mixed and Augmented Reality (ISMAR). New York: IEEE, 2018: 37-45.
- [3] HUANG Jia-wei, LIU Shi-guang. Robust simultaneous localization and mapping in low-light environment[J]. Computer Animation and Virtual Worlds, 2019, 30(3/4): 155-161.
- [4] WANG Jun, WANG Rui, WU An-wen. Improved gamma correction for visual SLAM in low-light scenes[C]//IEEE. 2019 IEEE 3rd Advanced Information Management, Communicates, Electronic and Automation Control Conference. New York: IEEE, 2019: 1159-1163.
- [5] LORE K G, AKINTAYO A, SARKAR S. LLNet: a deep autoencoder approach to natural low-light image enhancement[J]. Pattern Recognition, 2017, 61: 650-662.
- [6] WEI Chen, WANG Wen-jing, YANG Wen-han, et al. Deep retinex decomposition for low-light enhancement[J]. ArXiv, 2018, DOI: arXiv:1808.04560.
- [7] DABOV K, FOI A, KATKOVNIK V, et al. Image denoising by sparse 3-D transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-2095.
- [8] ZHANG Kai, ZUO Wang-meng, CHEN Yun-jin, et al. Beyond a Gaussian denoiser: residual learning of deep CNN for image denoising[J]. IEEE transactions on Image Processing, 2017, 26(7): 3142-3155.
- [9] QIN Tong, LI Pei-liang, SHEN Shao-jie. VINS-mono: a robust and versatile monocular visual-inertial state estimator[J]. IEEE Transactions on Robotics, 2018, 34(4): 1004-1020.
- [10] ROESLER C, LARSON K M. Software tools for GNSS interferometric reflectometry (GNSS-IR)[J]. GPS Solutions, 2018, 22(3): 987-995.
- [11] 章为川,孔祥楠,宋 文. 图像的角点检测研究综述[J]. 电子学报, 2015, 43(11): 2315-2321.
ZHANG Wei-chuan, KONG Xiang-nan, SONG Wen. Review of image corner detection algorithms[J]. Acta Electronica Sinica, 2015, 43(11): 2315-2321. (in Chinese)
- [12] LUCAS B D, KANADE T. An iterative image registration technique with an application to stereo vision[C]//IJCAI. Proceedings of the 7th International Joint Conference on Artificial Intelligence. Vancouver: IJCAI, 1981: 674-679.
- [13] AGARWAL S, SNAVELY N, SEITZ S M, et al. Bundle adjustment in the large[C]//Springer. 11th European Conference on Computer Vision. Berlin: Springer, 2010: 29-42.
- [14] 唐崇武. 图像统计建模与噪声分析关键技术的研究[D]. 上海:上海交通大学, 2015.
TANG Chong-wu. Research on key techniques of image statistical modeling and noise analysis[D]. Shanghai: Shanghai Jiao Tong University, 2015. (in Chinese)
- [15] 郝志成,吴 川,杨 航,等. 基于双边纹理滤波的图像细节增强方法[J]. 中国光学, 2016, 9(4): 423-431.
HAO Zhi-cheng, WU Chuan, YANG Hang, et al. Image detail enhancement method based on multi-scale bilateral

- texture filter[J]. Chinese Optics, 2016, 9(4): 423-431. (in Chinese)
- [16] LIN Hao-ming, SHI Zhen-wei. Multi-scale retinex improvement for nighttime image enhancement[J]. Optik, 2014, 125(24): 7143-7148.
- [17] HAN Nian-long, HU Jin-xing, ZHANG Wei. Multi-spectral and SAR images fusion via Mallat and À trous wavelet transform[C]//IEEE. 2010 18th International Conference on Geoinformatics. New York: IEEE, 2010: 1-4.
- [18] 田流芳. 基于中值滤波和小波变换的图像去噪算法研究[D]. 保定: 河北大学, 2014.
- TIAN Liu-fang. Research on image denoising algorithm based on median filtering and wavelet transform[D]. Baoding: Hebei University, 2014. (in Chinese)
- [19] FEBIN I P, JIDESH P, BINI A A. A retinex-based variational model for enhancement and restoration of low-contrast remote-sensed images corrupted by shot noise[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 941-949.
- [20] COSTA D S, MELLO C A B. Enhancement of weakly illuminated images using CNN and retinex theory[C]//IEEE. 2020 IEEE International Conference on Systems, Man, and Cybernetics. New York: IEEE, 2020: 2559-2564.
- [21] MA Shi-ping, MA Hong-qiang, XU Yue-lei, et al. A low-light sensor image enhancement algorithm based on HSI color model[J]. Sensors, 2018, 18(10): 524-536.
- [22] MUSTAFA W A, YAZID H, YAACOB S B. Illumination normalization of non-uniform images based on double mean filtering[C]//IEEE. 2014 IEEE international conference on control system, computing and engineering. New York: IEEE, 2014: 366-371.
- [23] 李晓飞. 基于小波变换的图像去噪方法研究[D]. 南京: 南京邮电大学, 2016.
- LI Xiao-fei. Research on image denoising method based on wavelet transform[D]. Nanjing: Nanjing University of Posts and Telecommunications, 2016. (in Chinese)
- [24] FERNANDES L C, DE MENEZES L R A X, LOUREIRO A J F. Using the unscented transform to reduce the number of measurements in drive tests[J]. SN Applied Sciences, 2021, 3(2): 145-152.
- [25] BURRI M, NIKOLIC J, GOHL P, et al. The EuRoC micro aerial vehicle datasets [J]. The International Journal of Robotics Research, 2016, 35(10): 1157-1163.
- [26] GEIGER A, LENZ P, STILLER C, et al. Vision meets robotics: the KITTI dataset[J]. The International Journal of Robotics Research, 2013, 32(11): 1231-1237.